Mạng DVRCNN cải tiến lớp hiếm trong IDS

Nguyễn Quốc Huy Phạm Duy Khánh

***Tóm tắt nội dung*—Trong bối cảnh các hệ thống mạng ngày càng đối mặt với những hình thức tấn công phức tạp, việc xây dựng hệ thống phát hiện xâm nhập (IDS) có khả năng hoạt động hiệu quả và bền vững trở thành yêu cầu cấp thiết. Nghiên cứu này đề xuất DVRCNN-IDS (Dual-View CNN for Rare-class & Robust IDS), một khung mô hình dựa trên kiến trúc hai góc nhìn CNN nhằm kết hợp đồng thời phân tích theo không gian đặc trưng (CNN 2D) và chuỗi thời gian (CNN 1D). Thiết kế này cho phép khai thác mối quan hệ giữa các thuộc tính mạng cũng như hành vi bất thường theo thời gian, từ đó nâng cao hiệu quả phát hiện tấn công. Để giải quyết vấn đề mất cân bằng dữ liệu, đặc biệt đối với các lớp tấn công hiếm (U2R, R2L), nghiên cứu tích hợp cơ chế học có trọng số theo lớp (Class-Weighted Learning) và kỹ thuật tái cân bằng dữ liệu, góp phần cải thiện khả năng nhận diện. Đồng thời, nhằm tăng cường khả năng chống chịu tấn công đối nghịch, mô hình được huấn luyện bổ sung với dữ liệu sinh bởi thuật toán tấn công FGSM [6] (Fast Gradient Sign Method). Kết quả thực nghiệm trên bộ dữ liệu NSL-KDD [14] cho thấy mô hình đạt độ chính xác tổng thể 82.43% và F1-score trung bình có trọng số 83.05%. Hệ thống vẫn giữ được hiệu năng ổn định trước các nhiễu đối kháng ở mức thấp, mặc dù còn hạn chế khi đối mặt với tấn công mạnh. Nghiên cứu đóng góp ba điểm chính: (i) đề xuất kiến trúc hai góc nhìn CNN cho IDS, (ii) áp dụng cơ chế huấn luyện chú trọng vào lớp hiếm để xử lý mất cân bằng dữ liệu, và (iii) tích hợp huấn luyện đối kháng nhằm nâng cao tính bền vững của hệ thống.**

***Từ khóa*—Phát hiện xâm nhập, Phòng thủ chống tấn công đối nghịch, Mạng nơ-ron tích chập, Lớp hiếm**

I. Giới thiệu

Các hệ thống mạng ngày càng đối mặt với nhiều hình thức xâm nhập phức tạp, đòi hỏi các hệ thống phát hiện xâm nhập (Intrusion Detection Systems — IDS) hiệu quả và bền vững. Các phương pháp dựa trên chữ ký/luật suy diễn khó thích ứng với tấn công mới (zero-day) và hành vi biến đổi, trong khi học sâu (deep learning) cho thấy tiềm năng khai thác mẫu ẩn từ dữ liệu mạng.

Bài báo đề xuất một mô hình CNN hai góc nhìn (dual-view CNN) kết hợp: (i) CNN 2D để khai thác quan hệ không gian giữa các đặc trưng khi biểu diễn dạng ma trận/ảnh; và (ii) CNN 1D để học động học theo chuỗi gói tin theo thời gian. Sự kết hợp này giúp tăng khả năng phát hiện tấn công.

Để khắc phục mất cân bằng dữ liệu (đặc biệt các lớp hiếm như U2R, R2L), mô hình áp dụng tái cân bằng dữ liệu và học chú trọng chi phí (cost-sensitive learning). Đồng thời, để nâng cao tính bền vững trước tấn công đối nghịch (adversarial attacks), mô hình sử dụng huấn luyện đối kháng (adversarial training), giúp duy trì độ tin cậy khi triển khai thực tế.

Kết quả sơ bộ: Các thí nghiệm ban đầu trên bộ dữ liệu NSL-KDD (KDDTest+) cho thấy mô hình đề xuất đạt độ chính xác tổng thể 82.43% và F1-score trung bình có trọng số 83.05%. Hiệu năng phân loại tốt được duy trì đối với lớp phổ biến như và DoS (Recall = 86.25%), trong khi lớp Probe đạt mức 83.23%, phản ánh khả năng nhận diện tương đối ổn định, lớp hiếm R2L được cãi thiện (77.33%). Tuy nhiên mô hình gặp khó khăn đáng kể với lớp hiếm U2R ở mức rất thấp (35.82%) do số lượng mẫu rất ít(67 mẫu). Mô hình không nhận diện tốt lớp Benign như các nghiên cứu khác (81.15%).

Đóng góp:

- **Mô hình CNN hai miền đặc trưng mới:** kết hợp đồng thời CNN 1D (góc nhìn chuỗi thời gian) và CNN 2D (góc nhìn không gian đặc trưng) , cho phép học đặc trưng toàn diện hơn và nâng cao hiệu quả phát hiện tấn công mạng.
- **Huấn luyện chú trọng vào lớp hiếm:** Áp dụng thuật toán tăng cường dữ liệu ADASYN để làm giàu dữ liệu của các lớp hiếm, sử dụng học có trọng số (Class-weighted Learning)
- **Tăng cường khả năng chống chịu tấn công đối nghịch:** tích hợp huấn luyện đối kháng nhằm bảo vệ mô hình trước các kỹ thuật tấn công như FGSM/PDG.

Tổ chức bài báo: phần 2 trình bày các công trình nghiên cứu liên quan, phần 3 trình bày phương pháp của bài báo này, phần 4 chuẩn bị môi trường, phần 5 kết quả bài báo, phần 6 kết luận và hướng phát triển.

II. Các công trình liên quan

Trong lĩnh vực IDS, nhiều nghiên cứu về tấn công đối nghịch và phòng thủ đã được khảo sát và thực nghiệm trên các bộ dữ liệu chuẩn như NSL-KDD, CIC-IDS2017/2018, UNSW-NB15. Ke He, Dan Kim và Muhammad Rizwan Asgha (2023) [8] tổng quan toàn diện AML cho IDS, hệ thống hóa các kiểu tấn công (white-box, black-box, game-theoretic), các chiến lược phòng thủ (huấn luyện đối kháng, GAN-based, dropout, phát hiện đối nghịch, tiền xử lý), nêu thách thức và định hướng tương lai (đặc biệt black-box). Haroon & Ali (2022) [7] so sánh FGSM và JSMA trên nhiều bộ dữ liệu và mô hình truyền thống, cho thấy huấn luyện đối kháng cải thiện hiệu năng; KNN/RF bền hơn, NB yếu hơn. Jmila & Ibn Khedher (2022) [9] đánh giá chín kiểu tấn công (FGSM, BIM, PGD, JSMA, DeepFool, C&W, ZOO, Boundary, HopSkipJump) và thử nghiệm tăng cường dữ liệu Gaussian, chỉ ra độ nhạy tùy mô hình và cung cấp khung đánh giá robustness. Một số hướng phòng thủ kết hợp cũng được đề xuất: Awad et al. (2025) [3] kết hợp huấn luyện đối kháng, làm mượt nhãn, tăng cường Gaussian, mã hóa khử nhiễu và bỏ phiếu đa số (Assamble) để nâng khả năng kháng nhiễu trên CIC-IDS2017/2018; Roshan et al. (2023) [13] cho thấy huấn luyện đối kháng là hiệu quả nhất trong ba quy tắc trên kịch bản hộp trắng (white-box) thời gian thực. Với NSL-KDD, Nathaniel & Soosai (2023) [11] đề xuất RF-RSE và RF-RSE-AT, tăng độ bền ngay cả khi không dùng dữ liệu đối nghịch trong huấn luyện; khi thêm đối kháng,

hiệu năng tiếp tục cải thiện. Vitorino et al. (2024) [15] tổng hợp nhiều phương pháp chọn đặc trưng, chứng minh kết hợp lựa chọn đặc trưng với huấn luyện đối kháng giúp duy trì hiệu năng, và mở rộng bộ chuẩn đánh giá A2PM cho bài toán tấn công đối nghịch. Từ các kết quả trên, khoảng trống còn lại là mô hình học sâu chuyên biệt vừa xử lý tốt mất cân bằng lớp (R2L, U2R), vừa bền vững trước tấn công mạnh (FGSM/PGD) — mục tiêu mà mô hình hướng tới bằng kiến trúc hai góc nhìn CNN, cơ chế huấn luyện chú trọng lớp hiếm và huấn luyện đối kháng.

III. Phương pháp đề xuất

A. Mục tiêu thiết kế và tổng quan

DVRCNN-IDS (Dual-View CNN for Rare-class & Robust IDS) tích hợp học đặc trưng hai chiều (dual-view feature learning) với các cơ chế được thiết kế riêng cho bộ dữ liệu mất cân bằng lớp và tăng cường khả năng chống tấn công đối nghịch trong phát hiện xâm nhập mạng. Quy trình của hệ thống gồm bốn thành phần chính:(i)**Tiền xử lý dữ liệu** bao gồm mã hóa, chuẩn hóa và tăng cường dữ liệu (ii) **Trích xuất đặc trưng 2 góc nhìn** để trích xuất đồng thời dữ liệu dạng bảng (1D) và dạng ma trận tương quan (2D); (iii) **Hợp nhất đặc trưng** hai chiều vào không gian đặc trưng ẩn chung để cải thiện khả năng nhận dạng các lớp hiếm;(iv) **Huấn luyện đối kháng**: sau khi hợp nhất đặc trưng, tiến hành **huấn luyện**: sử dụng (FGSM) để tạo mẫu đối nghịch, rồi huấn luyện mô hình.

B. Kiến trúc và ký hiệu

Mô hình DVRCNN-IDS được thiết kế theo hướng hai góc nhìn, khai thác đồng thời hai dạng biểu diễn của dữ liệu mạng:

- 1D: biểu diễn dạng chuỗi đặc trưng ban đầu của lưu lượng mạng.
- 2D : biểu diễn dạng ma trận tương quan hoặc hình ảnh chuyển đổi từ đặc trưng gốc.

Hai hướng nhìn này được xử lý riêng biệt dựa trên Mạng nơ ron tích chập (CNN), sau đó hợp nhất trong không gian đặc trưng ẩn (latent space) để phục vụ phân loại.

Các ký hiệu chính được sử dụng trong kiến trúc như sau:

- x: vector đặc trưng đầu vào của một mẫu.
- $f_{1D}(x)$: đặc trưng trích xuất từ **trích xuất 1D**.
- $f_{2D}(x)$: đặc trưng trích xuất từ **trích xuất 2D**.
- $z = \phi(f_{1D}(x), f_{2D}(x))$: vector đặc trưng được hợp nhất thông qua hợp nhất đặc trưng (Feature Fusion) trong **không gian ẩn**.
- logits $= Wz + b$: đầu ra tuyến tính trước khi áp dụng softmax.

C. Trích xuất và hợp nhất đặc trưng hai chiều

Trong DVRCNN-IDS, dữ liệu mạng được biểu diễn theo hai dạng đầu vào bổ sung cho nhau:

- **1D:** dữ liệu ở dạng chuỗi đặc trưng (feature vector) được đưa qua **trích xuất 1D**. Các tầng tích chập 1D có khả năng phát hiện các mối liên hệ cục bộ giữa các thuộc tính, giúp mô hình nhận diện tốt các dạng tấn công. Kết quả trích xuất được biểu diễn thành vector đặc trưng $f_{1D}(x)$.
- **2D :** dữ liệu được chuyển đổi thành ma trận tương quan hoặc ảnh xám 2D từ tập đặc trưng ban đầu. Đầu vào này đi qua **trích xuất 2D**, nơi các tầng tích chập 2D học được cấu trúc không gian (spatial correlation) giữa các thuộc tính. Đầu ra của nhánh này là vector đặc trưng $f_{2D}(x)$.

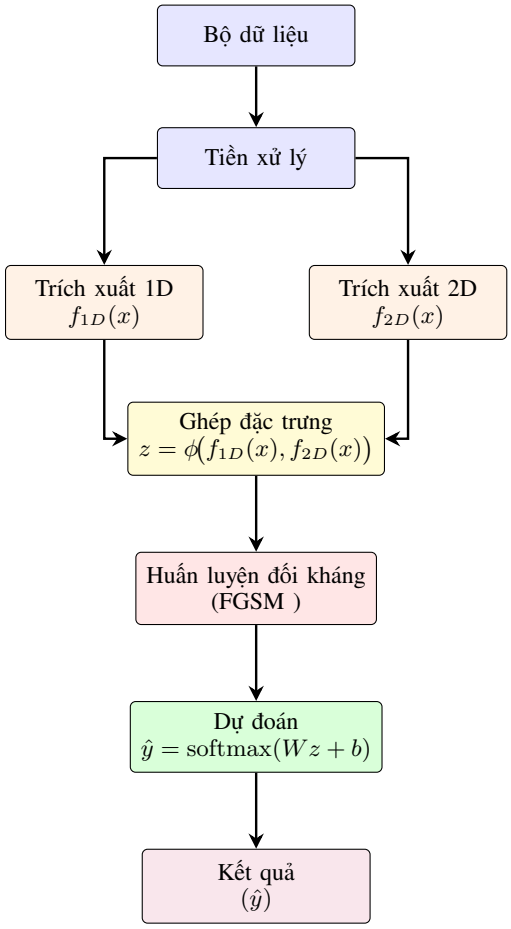

Hình 1. Quy trình huấn luyện.

Sau khi trích xuất, hai vector đặc trưng được hợp nhất bằng một hàm kết hợp $\phi(\cdot)$:

$$z = \phi(f_{1D}(x), f_{2D}(x))$$

Trong đó ϕ là phép **kết hợp** (Fusion) trực tiếp nhằm học cách kết hợp tối ưu. Vector z chính là biểu diễn đặc trưng hợp nhất trong không gian ẩn (latent space), mang thông tin cả từ miền tuần tự (1D) lẫn miền không gian (2D).

Việc sử dụng cơ chế trích xuất và hợp nhất đặc trưng hai chiều giúp mô hình DVRCNN-IDS tận dụng được lợi thế từ cả hai góc nhìn, từ đó cải thiện độ chính xác tổng thể và tăng khả năng nhận diện các lớp tấn công hiếm vốn thường khó phân biệt nếu chỉ dựa vào một dạng đặc trưng đơn lẻ.

D. Huấn luyện chú trọng vào lớp hiếm

Một thách thức quan trọng trong phát hiện xâm nhập mạng là sự **mất cân bằng dữ liệu** (class imbalance). Trong bộ dữ liệu NSL-KDD, các lớp tấn công như **DoS** và **Probe** chiếm tỉ lệ lớn, trong khi các lớp hiếm như **R2L** và **U2R** chỉ chiếm một phần rất nhỏ. Nếu không có biện pháp xử lý, mô hình dễ bị thiên lệch (bias) về các lớp phổ biến, dẫn đến độ chính xác thấp trên các lớp hiếm.

Để khắc phục vấn đề này, DVRCNN-IDS áp dụng cơ chế **Class-Weighted Learning**, trong đó trọng số của mỗi lớp c được điều chỉnh thông qua vector trọng số $w = [w_1, w_2, \ldots, w_C]$.

Ngoài ra trong bài báo còn sử dụng kỹ thuật **lấy mẫu tăng cường có chọn lọc** (oversampling) **ADASYN** để sinh thêm mẫu huấn luyện cho các lớp hiếm. Việc kết hợp đồng thời **trọng số lớp** và **tái cân bằng dữ liệu** giúp cải thiện khả năng nhận diện các lớp R2L và U2R.

E. Huấn luyện tăng cường chống tấn công đối nghịch

Các tấn công đối nghịch thêm nhiễu nhỏ δ để tăng loss và đánh lừa mô hình. Cụ thể, tạo mẫu đối nghịch:

$$x' = x + \epsilon \,\mathrm{sign}(\nabla_x \mathcal{L}(f_\theta(x), y)) \,,$$

và huấn luyện với (x', y). Cách này giúp duy trì độ chính xác trên dữ liệu sạch và tăng *độ chính xác bền vững* (robust accuracy) trong miền nhiễu nhỏ.

IV. Chuẩn bị môi trường

Phần này mô tả các tập dữ liệu, thiết lập tấn công đối nghịch, các chỉ số đánh giá và chi tiết triển khai được sử dụng để đánh giá hiệu năng của khung DVRCNN-IDS được đề xuất.

A. Bộ dữ liệu

Chúng tôi đánh giá phương pháp của mình trên bộ dữ liệu chuẩn thường được sử dụng trong phát hiện xâm nhập:

NSL-KDD : bao gồm 41 đặc trưng và 5 lớp (Benign, DoS, Probe, R2L, U2R). Bộ dữ liệu được tiền xử lý bằng cách sử dụng one-hot encoding cho các đặc trưng rời rạc, chuẩn hóa min-max cho các đặc trưng liên tục, tăng cường dữ liệu bằng ADASYN và chia phân tầng thành tập huấn luyện (80%), tập xác thực (20%) và tập kiểm tra có từ bộ dữ liệu gốc.

Sau đó, dữ liệu được tổ chức lại dưới dạng **cửa sổ trượt (sliding window)** với độ dài cửa sổ bằng 2 và bước nhảy bằng 1.

B. Cài đặt Tấn công đối nghịch

- Phương pháp dấu gradient nhanh - Fast Gradient Sign Method (FGSM). Thử nghiệm với các mức nhiễu $\varepsilon \in \{0.005, 0.01, 0.02, 0.05, 0.1\}$.
- Tấn công lặp nhiều bước - Projected Gradient Descent (PGD). Các tham số sử dụng trong thí nghiệm như sau:
  - *Thông số cho góc nhìn 1D :* bước học (step size) $\alpha_1 \in \{0.0005, 0.001, 0.0025\}$, và biên độ $\varepsilon_1 \in \{0.01, 0.02, 0.05\}$.
  - *Thông số cho góc nhìn 2D :* bước học $\alpha_2 \in \{0.0004, 0.0007, 0.0015\}$, và biên độ $\varepsilon_2 \in \{0.008, 0.015, 0.03\}$.
  - Số vòng lặp cho cả hai nhánh: $T = 20$ bước.

Các thiết lập trên mô phỏng các cuộc tấn công hộp trắng (white-box) mạnh nhằm kiểm tra độ bền (robustness).

C. Chỉ số đánh giá

Chúng tôi sử dụng kết hợp các chỉ số đánh giá truyền thống và các chỉ số có tính đến khả năng giải thích:

- **Độ chính xác sạch (Clean Accuracy):** độ chính xác phân loại trên các mẫu kiểm tra chưa bị nhiễu.
- **Độ chính xác bền vững (Robust Accuracy):** độ chính xác trên các mẫu kiểm tra bị nhiễu đối nghịch.
- **Các chỉ số IDS bổ sung:** chúng tôi theo dõi Precision, Recall, F1-score ở mức nội bộ để kiểm tra tính hợp lý, nhưng tập trung thảo luận vào Clean/Robust Accuracy.

D. Chi tiết triển khai

Chúng tôi triển khai **DVRCNN-IDS** bằng PyTorch. Mô hình bao gồm hai nhánh xử lý song song:

- **Nhánh 1D-CNN:** ba lớp tích chập 1D với số kênh tăng dần ($96 \to 192 \to 384$), kết hợp chuẩn hóa theo batch và hàm kích hoạt ReLU. Ánh xạ trực tiếp đầu vào sang không gian 384 chiều. Đầu ra được gom đặc trưng toàn cục và ánh xạ qua lớp tuyến tính xuống 96 chiều.
- **Nhánh 2D-CNN:** bốn lớp tích chập 2D với số kênh tăng dần ($48 \to 96 \to 192 \to 384$), mỗi lớp kết hợp chuẩn hóa theo batch và ReLU. Ánh xạ trực tiếp đầu vào sang không gian 384 chiều, trước khi cộng vào đường chính. Đặc trưng sau đó được gom toàn cục và nén về 96 chiều qua một lớp tuyến tính.
- **Cơ chế hợp nhất:** hai vector đặc trưng từ nhánh 1D và 2D được kết hợp, sau đó chiếu về không gian 96 chiều.
- **Bộ phân loại:** Đầu vào 96 chiều lần lượt đi qua các tầng tuyến tính 192, 96, chuẩn hóa theo batch, hàm kích hoạt ReLU và dropout, cuối cùng ánh xạ ra số lớp nhãn đầu ra (5 lớp).

Quá trình huấn luyện sử dụng bộ tối ưu Adamw (Adam with decoupled Weight Decay) với tốc độ học (learning rate) 5.10^{-4}, kích thước lô (batch size) 128 và 1000 epoch, áp dụng dừng sớm (Early Stopping) khi mô hình không cải thiện trong 50 lần lặp (epochs). Mô hình dùng hàm mất mát Focal (Focal Loss) với tham số $\gamma = 0.2$, cùng trọng số theo lớp (class weighting) với bộ trọng số $\{0.5151, 1.3407, 1.1160, 3.8281, 7.5389\}$ tương ứng với (Benign, DoS, Probe, R2L, U2R). Bộ điều lịch tốc độ học OneCycleLR (OneCycleLR Scheduler) với tốc độ học tối đa (max LR) 5.10^4 được dùng để cập nhật tốc độ học. Các mẫu đối nghịch (Adversarial examples) được sinh bằng FGSM với tham số $\epsilon = 0.02$. Toàn bộ thí nghiệm được thực hiện trên Kaggle, trang bị GPU NVIDIA Tesla T4 $\times$ 2 (57.6 GB bộ nhớ), CUDA 12.5.82, Python 3.11 và 30 GB RAM.

V. Kết quả và thảo luận

Phần này báo cáo hiệu năng thực nghiệm của DVRCNN-IDS và so sánh với các phương pháp cơ sở cũng như các cơ chế phòng thủ gần đây. Trước tiên, chúng tôi trình bày độ bền vững tổng thể trong phân loại và độ chính xác sạch.

A. Kết quả nghiên cứu

1) Kết quả cho bộ KDDTest+: Kết quả thực nghiệm cho thấy mô hình đạt độ chính xác tổng thể 82.43%, với F1-score trung bình có trọng số 83.05%. Đối với các lớp phổ biến như DoS, mô hình đạt hiệu năng tạm ổn (86.25%), phản ánh khả năng phân loại ổn định trên loại lưu lượng chiếm ưu thế. Lớp Probe đạt Recall 86.25%, cho thấy mô hình vẫn duy trì khả năng phát hiện tương đối tốt đối với các dạng tấn công thăm dò. Việc phân loại lớp hiếm như R2L cũng khá ổn định với recall = 77.33%. Tuy nhiên, hiệu năng suy giảm đáng kể ở các lớp hiếm, đặc biệt là U2R do số lượng mẫu hạn chế nên việc phân loại rất khó. Độ chính xác của Benign chỉ ở mức trung bình khi so với số lượng mẫu chiếm ưu thế.

Bảng I
Bảng kết quả cho bộ KDD Test+

	Precision	Recall	F1-Score	Support
Benign	94.04	81.15	87.12	9711
Dos	87.74	86.25	86.99	7460
Probe	69.13	83.23	75.52	2421
R2L	58.91	77.33	66.88	2885
U2R	18.46	35.82	24.37	67
Accuracy			82.43	22544
Macro Avg	65.66	72.75	68.17	22544
Weighted Avg	84.56	82.43	83.05	22544

2) Độ chính xác khi tấn công FGSM: Khi ϵ nhỏ (0.01–0.02), độ chính xác chỉ giảm nhẹ, từ khoảng 82% xuống $\sim 81\%$, cho thấy mô hình vẫn giữ được tính ổn định trước các nhiễu yếu. Khi ϵ tăng lên 0.05, độ chính xác giảm xuống $\sim 77\%$. Tại mức nhiễu mạnh ($\epsilon = 0.10$), độ chính xác chỉ còn $\sim 66\%$. Mô hình giữ được tính ổn định khi các tấn công nhiễu yếu nhưng nếu độ tấn công lớn thì độ chính xác của mô hình bị giảm đi đáng kể.

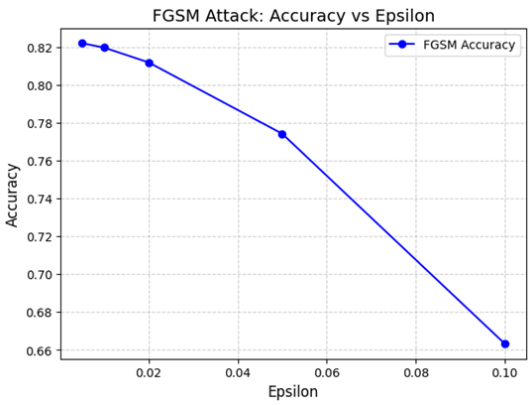

Hình 2. Độ chính xác của mô hình khi bị tấn công FGSM

3) Độ chính xác khi tấn công PGD: Ở mức ϵ nhỏ (0.01), độ chính xác của mô hình vẫn giữ ở mức cao, khoảng 82%, gần tương đương với khi không có tấn công. Khi ϵ tăng lên 0.02, độ chính xác giảm nhẹ xuống $\sim 81\%$, cho thấy ảnh hưởng bước đầu của nhiễu đối kháng. Với ϵ lớn hơn (0.05), độ chính xác giảm còn $\sim 77\%$, phản ánh rằng PGD có khả năng làm suy yếu mô hình rõ rệt khi cường độ tấn công tăng. So với FGSM, PGD thường được xem là tấn công mạnh hơn và lặp lại nhiều bước, tuy nhiên trong kết quả này mức suy giảm diễn ra tương đối thấp.

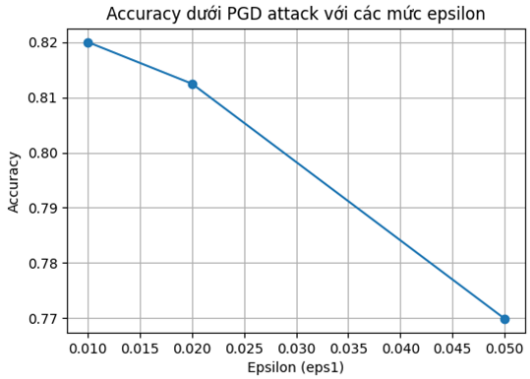

Hình 3. Độ chính xác của mô hình khi bị tấn công PGD

B. So sánh với các nghiên cứu khác

1) Bộ dữ liệu khi chưa bị tấn công đối nghịch: Để đánh giá hiệu quả của mô hình đề xuất, chúng tôi tiến hành so sánh với các phương pháp hiện có được công bố trong giai đoạn 2020–2024. Kết quả tổng hợp trong bảng cho thấy độ chính xác của các mô hình trước đây dao động từ 73.35% đến 78.72%. Trong đó, BiLSTM-DNN (2023) [5] đạt 78.72% và FlowTransformer (2024) [2] đạt 78.16% được xem là những phương pháp có hiệu năng cao nhất. Tuy nhiên, mô hình hai góc nhìn CNN của chúng tôi vượt trội hơn, đạt 82.43%. Lợi thế này xuất phát từ thiết kế, trong đó dữ liệu được khai thác song song theo hai miền 1D (chuỗi đặc trưng) và 2D (ma trận tương quan), cho phép mô hình học được nhiều thông tin ẩn mà các phương pháp trước đây chưa tận dụng triệt để. Việc kết hợp các góc nhìn bổ sung này giúp tăng khả năng phân biệt giữa các loại tấn công, đồng thời cải thiện độ chính xác tổng thể, tạo ra mức cải thiện khoảng 3.7–9% so với các nghiên cứu liên quan.

Bảng II
So sánh kết quả nghiên cứu với các nghiên cứu khác với bộ dữ liệu không tấn công

Phương pháp	Năm	Độ chính xác (%)
CNN-BiLSTM [1]	2020	76.45
BiDLSTM [12]	2021	76.96
BiLSTM-DNN [5]	2023	78.72
ABD [5]	2022	73.35
CANet [16]	2023	77.68
FlowTransformer [2]	2024	78.16
MECNN [4]	2022	74.73
EvoBMF [17]	2023	74.04
MENAS [10]	2024	77.77
Nghiên cứu này	**2025**	**82.43**

2) Bộ dữ liệu khi bị tấn công: Bảng trình bày hiệu năng của một số phương pháp dưới tấn công FGSM. Cụ thể, các phương pháp Adaboost, AF (2024) [9] chịu FGSM với ϵ = 0.01 và đạt khoảng 76%, trong khi các báo cáo về Random Forest (2023) [11] báo hiệu một dải hiệu năng rộng ($\sim$ 50.5%–75.2%) tuỳ theo cấu hình và thiết lập thí nghiệm. Nghiên cứu này đạt 82.2% dưới FGSM (ϵ = 0.01), cho thấy mô hình đề xuất không chỉ ổn định hơn mà còn có khả năng chống chịu tốt hơn trước cùng loại tấn công nhẹ. Sự khác biệt này đến từ thiết kế hai góc nhìn CNN, giúp khai thác đặc trưng dữ liệu theo cả miền 1D và 2D, kết hợp với cơ chế huấn luyện đối kháng và hàm mất mát có trọng số, nhờ đó mô hình học được đặc trưng bền vững hơn và giảm thiểu tác động của tấn công đối nghịch.

Bảng III
SO SÁNH KẾT QUẢ NGHIÊN CỨU VỚI CÁC NGHIÊN CỨU KHÁC VỚI BỘ DỮ LIỆU ĐÃ BỊ TẤN CÔNG

Phương pháp	**Năm**	**Cách tấn công**	**Độ chính xác (%)**
Adaboost, AF [9]	2024	FGSM($\sigma = 0.01$)	$\sim$76
RF [11]	2023	FGSM	50.47$\sim$75.15
Nghiên cứu này	**2025**	**FGSM**($\sigma = 0.01$)	**82.2**

VI. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Bài báo đề xuất **DVRCNN-IDS** — mô hình *hai góc nhìn CNN* kết hợp CNN 1D (chuỗi thời gian) và CNN 2D (không gian đặc trưng), cùng *huấn luyện chú trọng lớp hiếm* và *huấn luyện đối kháng* để xử lý mất cân bằng dữ liệu và tăng khả năng chống tấn công đối nghịch.

Trên NSL-KDD, mô hình vượt nhiều phương pháp hiện tại với **Accuracy 82.43%** và **F1 có trọng số 83.05%**; duy trì ổn định trên các lớp phổ biến (DoS, Probe), cải thiện nhận diện lớp hiếm (R2L 77.33%), và giữ vững hiệu năng ở mức nhiễu thấp FGSM/PGD.

Hạn chế còn lại:

- Độ bền vững suy giảm khi ϵ lớn (khi đạt ngưỡng ~ 0.1)
- Mặc dù độ chính xác của các lớp hiếm đã được cải thiện nhưng mô hình vẫn gặp khó khăn khi nhận diện vì số lượng mẫu ít (U2R 67 mẫu, độ chính xác 35.82%).
- Độ chính xác của Bening khá thấp so với số lượng mẫu(9711 mẫu, 81.15%).

Hướng phát triển:

- **Đa dạng dữ liệu**: CIC-IDS2017/2018, UNSW-NB15 để kiểm chứng tính khái quát.
- **Phòng thủ nâng cao**: thu gọn đặc trưng, bộ mã hóa khử nhiễu.
- **Học nâng cao**: học chuyển giao, học bán giám sát.
- **Đánh giá toàn diện**: tấn công hộp đen, đa giai đoạn.

Tổng kết, DVRCNN-IDS là hướng tiếp cận hứa hẹn cho IDS thông minh, khai thác hiệu quả đặc trưng đa chiều và tăng cường tính bền vững trước các mối đe dọa hiện đại.

TÀI LIỆU

[1] Estabraq Alars and Sefer Kurnaz. Enhancing network intrusion detection systems with combined network and host traffic features using deep learning: deep learning and iot perspective. *Discover Computing*, 27, 11 2024.

[2] Mohammad Ali, Ifiok Udoidiok, Fuhao Li, and Jielun Zhang. A review on generative intelligence in deep learning based network intrusion detection. pages 1–9, 2024.

[3] Zeinab Awad, Magdy Zakaria, and Rasha Hassan. An enhanced ensemble defense framework for boosting adversarial robustness of intrusion detection systems. *Scientific Reports*, 15, 04 2025.

[4] Yi Chen, Qiuzhen Lin, Wenhong Wei, Junkai Ji, Ka-Chun Wong, and Carlos A. Coello Coello. Intrusion detection using multi-objective evolutionary convolutional neural network for internet of things in fog computing. *Knowledge-Based Systems*, 244, May 2022.

[5] Paulo Freitas de Araujo-Filho, Mohamed Naili, Georges Kaddoum, Emmanuel Thepie Fapi, and Zhongwen Zhu. Unsupervised gan-based intrusion detection system using temporal convolutional networks and self-attention. *IEEE Transactions on Network and Service Management*, 20(4):4951–4963, 2023.

[6] Ian J. Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples. *CoRR*, abs/1412.6572, 2014.

[7] Shahzad Haroon and Husnain Ali. Adversarial training against adversarial attacks for machine learning-based intrusion detection systems. *Computers, Materials Continua*, 73:3513–3527, 06 2022.

[8] Ke He, Dan Kim, and Muhammad Rizwan Asghar. Adversarial machine learning for network intrusion detection systems: A comprehensive survey. *IEEE Communications Surveys Tutorials*, PP:1–1, 01 2023.

[9] Houda Jmila and Mohamed Ibn Khedher. Adversarial machine learning for network intrusion detection: A comparative study. *Computer Networks*, 214:109073, 2022.

[10] Qiuzhen Lin, Zhihao Liu, Yeming Yang, Ka-Chun Wong, Yahui Lu, and Jianqiang Li. Multi-objective evolutionary neural architecture search for network intrusion detection. *Swarm Evol. Comput.*, 91:101702, 2024.

[11] D. NATHANIEL and A. SOOSAI. A robust network intrusion detection system using random forest based random subspace ensemble to defend against adversarial attacks. *Advances in Electrical and Computer Engineering*, 23:81–88, 01 2023.

[12] Andrea Pinto, Luis-Carlos Herrera, Yezid Donoso, and Jairo A. Gutierrez. Survey on intrusion detection systems based on machine learning techniques for the protection of critical infrastructure. *Sensors*, 23(5), 2023.

[13] Khushnaseeb Roshan, Aasim Zafar, and Sheikh Haque. Untargeted white-box adversarial attack with heuristic defence methods in real-time deep learning based network intrusion detection system. 10 2023.

[14] Mahbod Tavallaee, Ebrahim Bagheri, Wei Lu, and Ali A. Ghorbani. A detailed analysis of the kdd cup 99 data set. pages 1–6, 2009.

[15] João Vitorino, Miguel Silva, Eva Maia, and Isabel Praça. Reliable feature selection for adversarially robust cyber-attack detection. *annals of telecommunications - annales des télécommunications*, pages 1–15, 06 2024.

[16] Zhen Wang and Fuad Ghaleb. An attention-based convolutional neural network for intrusion detection model. *IEEE Access*, PP:1–1, 01 2023.

[17] Wenhong Wei, Yi Chen, Qiuzhen Lin, Junkai Ji, Ka-Chun Wong, and Jianqiang Li. Multi-objective evolving long–short term memory networks with attention for network intrusion detection. *Applied Soft Computing*, 139, May 2023.